

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
Национальный исследовательский университет ИТМО

Отчёт по лабораторной работе
Метрические методы классификации
Кейс №5

Выполнили:

Лорс Алина, 474321, J3214

Абаянцева Евгения, 327004, J3211

Смольникова Юлия, 474363, J3211

Санкт-Петербург, 2026

Содержание

1. Введение.....	3
1.1. Постановка задачи	3
1.2. Цели работы	3
1.3. Структура исследования	4
2. Математические предпосылки	4
2.1. Обучающая выборка и задача классификации	4
2.2. Расстояние между объектами и метрика Минковского.....	5
2.3. Почему важно масштабирование признаков.....	5
2.4. Упорядочивание соседей и правило голосования	5
2.5. Частные случаи общего метрического правила.....	6
2.6. Окно Парзена и роль ядра	7
2.7. LOO-контроль и оценка качества.....	8
2.8. Связь профиля компактности с 1NN	8
3. Реализованные методы	9
3.1. 1NN, kNN и weighted-kNN.....	9
3.2. Окно Парзена фиксированной и переменной ширины	9
3.3. Профиль компактности	9
3.4. Жадный отбор эталонов	9
4. Численные эксперименты	10
4.1. Датасеты и подготовка данных	10
4.2. Влияние масштабирования.....	10
4.3. Подбор параметров через LOO	11
4.4. Графики ошибок и карты классификации	11
4.5. Сравнение kNN и weighted-kNN при шуме.....	14
4.6. Профиль компактности и отбор эталонов.....	15
5. Вывод.....	16
6. Заключение	17
Код и воспроизводимость	18
Список использованных источников	18

1. Введение

1.1. Постановка задачи

В метрической классификации предполагается, что близкие объекты должны иметь близкие или одинаковые ответы. Поэтому для нового объекта класс определяется не через явную формулу разделяющей поверхности, а через расстояния до объектов обучающей выборки. Такой подход удобен для задач, где сложно заранее задать вид границы между классами, но можно осмысленно измерить близость объектов в пространстве признаков.

В работе рассматривается обучающая выборка объектов с известными классами. Требуется реализовать несколько метрических классификаторов, подобрать их параметры и сравнить качество на реальных и синтетических данных. Проверяется, как на результат влияют расстояние между объектами, число соседей, ширина окна Парзена, тип ядра, параметр метрики и предварительное масштабирование признаков.

1.2. Цели работы

Цель работы - исследовать частные случаи обобщённого метрического классификатора и показать, как выбор метрики, числа соседей, ширины окна, ядра и масштабирования признаков влияет на качество и устойчивость классификации.

- I. реализовать 1NN, kNN, weighted-kNN, окно Парзена фиксированной ширины и окно Парзена переменной ширины;
- II. реализовать взвешенную метрику Минковского с параметром p ;
- III. подобрать параметры k , p , h и тип ядра по LOO-контролю;
- IV. проверить влияние масштабирования признаков на качество классификации;
- V. построить графики LOO-ошибки, карты классификации и границы решения на `make_moons`;
- VI. исследовать поведение weighted-kNN при разном уровне шума;
- VII. вычислить профиль компактности и проверить его связь с качеством 1NN;
- VIII. реализовать простой жадный отбор эталонов для ускорения 1NN.

1.3. Структура исследования

Раздел 2 вводит математические обозначения, метрику Минковского, правило голосования, окна Парзена, LOO-контроль и профиль компактности. Раздел 3 описывает реализованные алгоритмы. В разделе 4 приведены численные эксперименты, таблицы и графики. Раздел 5 содержит обсуждение результатов и ограничений работы. Раздел 6 формулирует итоговые выводы.

2. Математические предпосылки

2.1. Обучающая выборка и задача классификации

Рассматривается задача классификации в d -мерном признаковом пространстве. Каждый объект описывается вектором числовых признаков, а его метка принадлежит конечному множеству классов Y . Обучающая выборка задаётся:

$$D_\ell = \{(x_i, y_i)\}_{i=1}^\ell, \quad x_i \in \mathbb{R}^d, \quad y_i \in Y$$

где ℓ - объём выборки. Требуется построить классификатор

$$a: \mathbb{R}^d \rightarrow Y$$

который для нового объекта x возвращает оценку его класса. Предположение метрической классификации - гипотеза компактности: объекты, близкие в выбранной метрике, с высокой вероятностью имеют одинаковую метку класса. Поэтому качество метода напрямую зависит от того, насколько корректно функция расстояния отражает содержательную близость объектов.

2.2. Расстояние между объектами и метрика Минковского

В качестве функции расстояния используется взвешенная метрика Минковского порядка p :

$$\rho_p(x, x_i) = \left(\sum_{j=1}^d w_j |x_j - x_{ij}|^p \right)^{1/p}, \quad w_j > 0, \quad p \geq 1$$

Здесь x_j - j -й признак классифицируемого объекта, x_{ij} - j -й признак i -го объекта обучающей выборки, w_j - вес j -го признака. Условие $p \geq 1$ задаёт корректную метрику, а положительные веса позволяют регулировать вклад отдельных координат в расстояние. В экспериментах использовались единичные веса признаков $w_j = 1$; При $p = 1$ получается расстояние Манхэттена, при $p = 2$ евклидово расстояние. Увеличение p усиливает влияние координат с крупными отклонениями, поэтому выбор p может изменить порядок ближайших соседей и форму решающей границы.

2.3. Почему важно масштабирование признаков

Стандартизация необходима, поскольку метрические алгоритмы не инвариантны к изменению масштаба признаков. Если признаки измерены в разных диапазонах, координата с

большим числовым разбросом может доминировать в расстоянии независимо от своей информативности. Для устранения этой проблемы применяется стандартизация:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad j = 1, \dots, d$$

В формуле μ_j и σ_j обозначают среднее и стандартное отклонение j -го признака. Если $\sigma_j = 0$, признак имеет нулевую дисперсию и должен быть исключён либо обработан отдельно. В train/test-экспериментах эти статистики вычисляются только по обучающей части выборки, после чего применяются к тестовой части; это предотвращает утечку информации из теста. В LOO-подборе стандартизация выполняется внутри каждого LOO-шага, параметры масштабирования считаются по выборке без проверяемого объекта, затем применяются к исключённому объекту.

2.4. Упорядочивание соседей и правило голосования

Для фиксированного классифицируемого объекта x все элементы обучающей выборки упорядочиваются по неубыванию расстояния:

$$\rho_p(x, x_{(1)}(x)) \leq \rho_p(x, x_{(2)}(x)) \leq \dots \leq \rho_p(x, x_{(\ell)}(x))$$

Обозначение $x_{(i)}(x)$ означает i -го ближайшего соседа объекта x после сортировки по расстоянию; соответствующая метка обозначается $y_{(i)}(x)$. Поддержка класса y вычисляется как взвешенная сумма голосов соседей:

$$\Gamma_y(x) = \sum_{i=1}^{\ell} \mathbf{1}\{y_{(i)}(x) = y\} q_i(x)$$

Индикатор равен 1, если условие внутри фигурных скобок выполнено, и равен 0 иначе. Функция $q_i(x)$ задаёт вес i -го соседа в голосовании; чем больше $\Gamma_y(x)$, тем сильнее поддержка класса y . Итоговое метрическое правило классификации выбирает класс с максимальной суммарной поддержкой:

$$a(x; D_\ell) = \arg \max_{y \in Y} \Gamma_y(x)$$

Если для нескольких классов достигается одинаковый максимум, применяется заранее фиксированное правило разрешения ничьей, а именно выбирается класс ближайшего объекта среди классов-победителей.

2.5. Частные случаи общего метрического правила

Метод 1NN получается, если учитывается только один ближайший сосед:

$$q_i(x) = \mathbf{1}\{i \leq 1\}$$

Тогда новый объект получает класс самого близкого объекта из обучающей выборки.

Метод kNN получается, если одинаково учитываются k ближайших соседей:

$$q_i(x) = \mathbf{1}\{i \leq k\}, \quad 1 \leq k \leq \ell$$

В этом случае решение принимается большинством голосов среди k соседей. Если k мало, граница классификации получается резкой и чувствительной к шуму. Если k слишком велико, граница становится слишком сглаженной, потому что в голосование попадают более дальние и менее похожие объекты.

В weighted-kNN веса соседей зависят от их ранга, более близкие объекты получают больший вклад, чем более дальние:

$$q_i(x) = \mathbf{1}\{i \leq k\} v_i, \quad v_i = \frac{1}{i}$$

В экспериментах для weighted-kNN использовалось ранговое взвешивание $v_i = 1/i$: ближайший сосед получает вес 1, второй-1/2, третий-1/3 и т.д. Поэтому учитывается не только число соседей каждого класса, но и степень локальной близости.

2.6. Окно Парзена и роль ядра

Окно Парзена задаёт веса объектов через ядровую функцию K от нормированного расстояния. Для фиксированной ширины окна $h > 0$ классификатор имеет вид:

$$a(x; D_\ell, h, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} \mathbf{1}\{y_i = y\} K\left(\frac{\rho_p(x, x_i)}{h}\right)$$

Параметр h задаёт масштаб локальной окрестности вокруг объекта x. Малое h делает метод более локальным и чувствительным к шуму, большое h приводит к сглаживанию решения и может скрыть локальную структуру классов. Ядро K переводит нормированное расстояние в неотрицательный вес. В работе рассматриваются равномерное, треугольное, ядро Епанечникова и гауссово ядро:

$$K_{uniform}(u) = \mathbf{1}\{|u| \leq 1\}, \quad K_{triangular}(u) = (1 - |u|)\mathbf{1}\{|u| \leq 1\}$$

$$K_{Epanechnikov}(u) = \frac{3}{4}(1 - u^2)\mathbf{1}\{|u| \leq 1\}, \quad K_{Gaussian}(u) = \frac{1}{\sqrt{2\pi}}e^{-u^2/2}$$

В формуле равномерного ядра используется $K_{uniform}(u) = \mathbf{1}\{|u| \leq 1\}$;

Для переменного окна Парзена ширина окна выбирается адаптивно и зависит от плотности объектов в окрестности точки x :

$$h_k(x) = \rho_p(x, x_{(k+1)}(x))$$

Если наблюдения вокруг x расположены плотно, расстояние до $(k + 1)$ -го соседа мало и окно становится узким. В разреженных областях окно расширяется, поэтому переменное окно Парзена лучше адаптируется к неоднородной плотности данных.

2.7. LOO-контроль и оценка качества

Для выбора гиперпараметров используется полный скользящий контроль leave-one-out. Для каждого объекта строится предсказание по выборке, из которой этот объект временно исключён, после чего считается доля ошибок.

$$LOO(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbf{1}\{y_i \neq a_{\theta}(x_i; D_{\ell} \setminus \{(x_i, y_i)\})\}$$

Здесь θ обозначает набор гиперпараметров метода, например k , p , h и тип ядра K . Малая LOO-ошибка означает, что локальное окружение объектов согласовано с их истинными метками, поэтому выбранные гиперпараметры адекватно описывают геометрию данных.

Дополнительно используются ассигасу и макро-F1. Для тестовой выборки размера m точность вычисляется как

$$accuracy = \frac{1}{m} \sum_{i=1}^m \mathbf{1}\{\hat{y}_i = y_i\}$$

$$Precision_y = \frac{TP_y}{TP_y + FP_y}, \quad Recall_y = \frac{TP_y}{TP_y + FN_y}, \quad F1_y = \frac{2 Precision_y Recall_y}{Precision_y + Recall_y}$$

$$macro-F1 = \frac{1}{|Y|} \sum_{y \in Y} F1_y$$

Для каждого класса качество сначала вычисляется отдельно, а затем усредняется по всем классам. Макро-F1 усредняет качество по классам с одинаковым весом, поэтому крупный класс не доминирует в итоговой оценке, в отличие от ассигасу. Это особенно важно при дисбалансе классов.

2.8. Связь профиля компактности с 1NN

Профиль компактности количественно описывает, насколько часто ближайшие соседи объекта принадлежат тому же классу. Для номера соседа m он задаётся формулой:

$$P(m) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbf{1}\{y_i \neq y_i^{(m)}\}, \quad m = 1, \dots, \ell - 1$$

Здесь $y_i^{(m)}$ - метка m -го ближайшего соседа объекта x_i среди остальных объектов выборки, то есть сам x_i при поиске соседей исключается. При одинаковой метрике, одинаковом масштабировании и одинаковом правиле разрешения ничьих значение $P(1)$ совпадает с LOO-ошибкой метода 1NN.

3. Реализованные методы

3.1. 1NN, kNN и weighted-kNN

Метод 1NN используется как базовый вариант. Класс нового объекта берётся у ближайшего объекта обучающей выборки.

Метод kNN учитывает уже не одного, а несколько ближайших соседей. Итоговый класс выбирается голосованием, поэтому случайная ошибка одного объекта влияет меньше. Слишком большое k может чрезмерно сгладить решение и потерять локальные особенности классов.

weighted-kNN реализует ранговое взвешивание, в работе используется $v_i = 1/i$, поэтому вклад соседа уменьшается с ростом его номера в отсортированном списке. Это делает ближайшие объекты более влиятельными, чем дальние.

3.2. Окно Парзена фиксированной и переменной ширины

Окно Парзена обобщает голосование соседей, вклад объекта определяется не только фактом попадания в окрестность, но и значением ядровой функции от нормированного расстояния. В фиксированном окне ширина h задаётся заранее. В переменном окне ширина $h_k(x)$ определяется расстоянием до $(k + 1)$ -го соседа, поэтому в плотных областях радиус окна уменьшается, а в разреженных увеличивается. В экспериментах сравнивались равномерное, треугольное, ядро Епанечникова и гауссово ядро.

3.3. Профиль компактности

Профиль компактности показывает долю объектов, для которых m -й ближайший сосед принадлежит другому классу. Чем меньше $P(m)$, тем лучше классы локально разделены в выбранной метрике. Значение $P(1)$ совпадает с LOO-ошибкой 1NN при одинаковой метрике, одинаковом масштабировании и одинаковом правиле разрешения ничьих.

3.4. Жадный отбор эталонов

Эталоны - это подмножество обучающих объектов, по которому затем выполняется классификация. Отбор эталонов нужен для ускорения 1NN, вместо расстояний до всех объектов модель считает расстояния только до выбранных представителей.

В работе реализованы два подхода. При последовательном удалении алгоритм начинает со всех объектов базовой подвыборки и удаляет объект, если качество на validation-части не ухудшается. При последовательном добавлении алгоритм начинает с одного типичного объекта каждого класса и добавляет объекты, которые повышают качество на validation-части. Тестовая выборка используется только для итоговой оценки.

4. Численные эксперименты

4.1. Датасеты и подготовка данных

Для экспериментов использованы три реальных набора данных из `sklearn.datasets`: Iris, Wine и Breast Cancer Wisconsin. Для визуализации границ решения дополнительно использован синтетический набор `make_moons`.

В экспериментах с train/test-разделением использовались `stratify = y`, `test_size = 0.3` и `random_state = 42`, чтобы сохранить пропорции классов. Для train/test-проверок параметры стандартизации считались только по обучающей части. Для LOO-подбора стандартизация выполнялась строго внутри каждого LOO-шага, чтобы проверяемый объект не участвовал в вычислении среднего и стандартного отклонения.

4.2. Влияние масштабирования

Первый эксперимент показывает, насколько метрические методы чувствительны к масштабу признаков. Для каждого набора данных сравнивается kNN при $k = 5$ и $p = 2$ без стандартизации и со стандартизацией.

Таблица 1. Влияние масштабирования признаков на качество kNN

Набор данных	Масштабирование	Метод	k	p	Accuracy	Macro-F1
Iris	нет	kNN	5	2	0.9778	0.9778
Iris	да	kNN	5	2	0.9111	0.9095
Wine	нет	kNN	5	2	0.6667	0.6667
Wine	да	kNN	5	2	0.9444	0.9441
Breast Cancer	нет	kNN	5	2	0.9240	0.9186
Breast Cancer	да	kNN	5	2	0.9591	0.9552

Масштабирование улучшило качество на Wine и Breast Cancer, потому что признаки в этих наборах данных имеют разные диапазоны значений. На Iris результат без масштабирования оказался выше только на выбранном train/test-разбиении. Поэтому строгий вывод по Iris требовал бы повторения эксперимента на нескольких разбиениях или использования кросс-валидации.

4.3. Подбор параметров через LOO

Параметры k , p , h и тип ядра подбирались по LOO-ошибке. В эксперименте использовались сетки $p \in \{1, 2, 3\}$ и $k \in \{1, 3, 5, 7, 9, 15\}$. Для фиксированного окна Парзена значения h выбирались по квантилям 0.05, 0.10, 0.20 и 0.35 попарных расстояний. Проверялись ядра uniform, triangular, epanechnikov и gaussian. При LOO-оценивании стандартизация выполнялась без проверяемого объекта. Сетка h формировалась заранее как фиксированный набор кандидатов по квантилям попарных расстояний, а сама LOO-оценка для каждого кандидата выполнялась с исключением проверяемого объекта. Breast Cancer не включался в полный LOO-подбор из-за большей вычислительной стоимости и использовался в экспериментах по масштабированию и профилю компактности.

Таблица 2. Лучшие результаты подбора параметров через LOO

Набор данных	Лучший результат	LOO-ошибка	Качество
Iris	переменное окно Парзена ($p=2$, $k=15$, $K=\text{epanechnikov}$); kNN ($p=2$, $k=15$); переменное окно Парзена ($p=2$, $k=15$, $K=\text{uniform}$); kNN ($p=3$, $k=15$)	0.0333	0.9667
Wine	переменное окно Парзена ($p=1$, $k=1$, $K=\text{gaussian}$); переменное окно Парзена ($p=1$, $k=3$, $K=\text{gaussian}$); переменное окно Парзена ($p=2$, $k=1$, $K=\text{gaussian}$)	0.0169	0.9831

Подбор параметров показал, что 1NN не всегда является лучшим методом. Он опирается только на одного соседа, поэтому сильнее реагирует на локальные ошибки. Для повышения устойчивости часто помогают несколько соседей или окно Парзена.

4.4. Графики ошибок и карты классификации

Для Iris построены три графика: зависимость LOO-ошибки от числа соседей k , зависимость LOO-ошибки от ширины окна h и зависимость LOO-качества от параметра p в метрике Минковского. LOO-качество вычисляется как $1 - \text{LOO-ошибка}$. Во всех трёх графиках используется LOO-схема со стандартизацией внутри каждого шага. Для графика по k фиксировано $p = 2$; для графика по h используется фиксированное окно Парзена с gaussian-ядром и $p = 2$; для графика по p используется kNN при $k = 5$.




Рисунок 1. Зависимость LOO-ошибки от числа соседей k для Iris при $p = 2$.




Рисунок 2. Зависимость LOO-ошибки от ширины окна h для Iris: фиксированное окно Парзена, gaussian-ядро, $p = 2$.




Рисунок 3. Зависимость LOO-качества от параметра p в метрике Минковского для Iris: kNN , $k = 5$.

По графикам видно, что умеренно большое число соседей уменьшает влияние отдельных объектов. Слишком широкое окно Парзена ухудшает качество, потому что начинает учитывать менее похожие объекты. На выбранном эксперименте меньшие значения p уменьшали доминирование координат с крупными отклонениями и давали большее LOO-качество.

Для двумерного синтетического набора данных `make_moons` построены карты классификации и явно выделены границы решения. Они наглядно показывают, как k и h меняют форму разделяющей линии. Для анализа использованы карты kNN при $k = 1$, $k = 5$, $k = 15$, а также карты окна Парзена при $h = 0.15$, $h = 0.35$ и $h = 0.8$.




Рисунок 4. Карта классификации kNN при $k = 1$.




Рисунок 5. Карта классификации kNN при $k = 5$.




Рисунок 6. Карта классификации kNN при $k = 15$.




Рисунок 7. Карта классификации окна Парзена при $h = 0.15$.




Рисунок 8. Карта классификации окна Парзена при $h = 0.35$.




Рисунок 9. Карта классификации окна Парзена при $h = 0.8$.

Карты классификации показывают, что малые k и h дают более резкую и чувствительную границу, а большие значения сглаживают решение. Слишком сильное сглаживание может ухудшить качество, потому что модель перестаёт учитывать локальную форму классов.

4.5. Сравнение kNN и weighted-kNN при шуме

Для проверки устойчивости weighted-kNN использовался make_moons с разным уровнем шума. Для каждого уровня шума эксперимент повторялся 20 раз, после чего усреднялась ассурасу и считалось стандартное отклонение. Это делает вывод осторожнее, чем сравнение по одному запуску.

Таблица 3. Сравнение kNN и weighted-kNN при разном уровне шума

Шум	k	Accuracy kNN	Std kNN	Accuracy weighted-kNN	Std weighted-kNN	Разница
0.05	15	1.0000	0.0000	1.0000	0.0000	0.0000
0.15	15	0.9863	0.0096	0.9871	0.0097	0.0008
0.25	15	0.9363	0.0235	0.9325	0.0201	-0.0038
0.35	15	0.8817	0.0242	0.8729	0.0225	-0.0088

По таблице видно, что weighted-kNN не является универсально лучшим методом. При малом шуме методы дали одинаковое качество, при noise = 0.15 weighted-kNN оказался

немного лучше, а при $\text{noise} = 0.25$ и 0.35 обычный kNN дал более высокую среднюю ассурасу. При этом различия остаются небольшими по сравнению с разбросом результатов, поэтому преимущество рангового взвешивания нужно проверять на конкретных данных и выбранном k .

4.6. Профиль компактности и отбор эталонов

Профиль компактности был построен для Iris, Wine и Breast Cancer. Чем ниже значение $\Pi(m)$, тем чаще m -й сосед имеет тот же класс. Для $m = 1$ профиль совпадает с LOO-ошибкой 1NN при одинаковой метрике и одинаковом масштабировании. На графиках показаны первые 25 значений m , поскольку ближайшие соседи наиболее информативны для анализа локальной структуры.



Рисунок 10. Профиль компактности для Iris.



Рисунок 11. Профиль компактности для Wine.



Рисунок 12. Профиль компактности для Breast Cancer.

Таблица 4. Сравнение $\Pi(1)$ и LOO-ошибки 1NN

Набор данных	$\Pi(1)$	LOO-ошибка 1NN	Комментарий
Iris	0.0533	0.0533	совпадает при той же метрике и той же схеме масштабирования
Wine	0.0449	0.0449	совпадает при той же метрике и той же схеме масштабирования
Breast Cancer	0.0492	0.0492	совпадает при той же метрике и той же схеме масштабирования

Низкие значения $P(1)$ показывают, что ближайший сосед в большинстве случаев принадлежит тому же классу. Совпадение $P(1)$ с LOO-ошибкой 1NN логично, потому что в обоих случаях объект сравнивается с ближайшим соседом среди остальных объектов. При росте m значения профиля обычно увеличиваются, более дальние соседи хуже отражают локальную принадлежность к классу.

Таблица 5. Сравнение полного 1NN и 1NN по отобранным эталонам

Набор данных	Метод	Число эталонов	Test accuracy	Время предсказания, мс
Iris	full train 1NN	105	0.9333	0.2804
Iris	greedy deletion	5	0.9111	0.0304
Iris	greedy addition	4	0.8889	0.0261
Wine	full train 1NN	124	0.9630	0.8525
Wine	greedy deletion	5	0.9074	0.0428
Wine	greedy addition	3	0.9074	0.0446

Для отбора эталонов обучающая часть сначала делилась на base и validation. Validation-часть использовалась только для выбора эталонов, а итоговое качество проверялось на независимой test-части. В строке full train 1NN baseline использует всю обучающую часть после train/test-разделения; методы greedy deletion и greedy addition используют только отобранные эталоны из base-подвыборки. Для Iris жадное удаление оставило 5 эталонов и дало test accuracy = 0.9111 против 0.9333 у полного 1NN. Для Wine после отбора осталось 5 или 3 эталона, качество снизилось сильнее, но время предсказания стало существенно меньше. Значения времени являются иллюстрацией ускорения и могут отличаться при повторном запуске из-за состояния интерпретатора и аппаратной среды.

5. Вывод

Во-первых, метрические методы классификации сильно зависят от масштаба признаков. Это особенно заметно на наборах Wine и Breast Cancer, где стандартизация признаков привела к росту accuracy и macro-F1. Это объясняется тем, что без масштабирования признаки с большими числовыми диапазонами начинают сильнее влиять на расстояние, даже если они не являются более информативными. На Iris стандартизация не дала улучшения на выбранном разбиении, поэтому для этого набора данных результат следует считать частным случаем конкретного train/test-разделения.

Во-вторых, выбор числа соседей k влияет на баланс между чувствительностью и устойчивостью классификатора. При $k = 1$ метод 1NN хорошо отражает локальную структуру данных, но сильно зависит от отдельных объектов, шума и выбросов. При увеличении k решение становится более устойчивым, так как класс определяется голосованием нескольких

соседей. Однако слишком большое k может чрезмерно сгладить границу классификации и ухудшить качество на данных со сложной локальной структурой.

В-третьих, ширина окна Парзена h выполняет похожую роль: малое h делает классификатор более локальным и чувствительным к шуму, а большое h усиливает сглаживание. На графиках и картах классификации видно, что при увеличении h граница решения становится более простой, но при слишком широком окне модель начинает учитывать слишком далёкие объекты и может хуже разделять классы.

В-четвёртых, weighted-kNN не показал универсального преимущества над обычным kNN . В эксперименте на `make_moons` при некоторых уровнях шума weighted-kNN давал немного лучший результат, но при более сильном шуме обычный kNN оказался не хуже или даже немного лучше. Поэтому ранговое взвешивание нельзя считать автоматически лучшим подходом, его эффективность зависит от структуры данных, уровня шума и выбранного значения k .

В-пятых, профиль компактности подтвердил связь между локальной однородностью классов и качеством метода $1NN$. Значение $P(1)$ совпало с LOO-ошибкой $1NN$ при одинаковой метрике и одинаковой схеме масштабирования. Это показывает, что профиль компактности можно использовать как дополнительный инструмент анализа, а именно если ближайшие соседи часто принадлежат другому классу, то $1NN$ будет чаще ошибаться.

В-шестых, жадный отбор эталонов позволил значительно уменьшить число объектов, участвующих в предсказании, и ускорить работу $1NN$. При этом качество снизилось не критически на `Iris`, но заметнее на `Wine`. Следовательно, отбор эталонов полезен как способ ускорения классификации.

6. Заключение

В работе были реализованы и исследованы основные метрические методы классификации: $1NN$, kNN , weighted-kNN , окно Парзена фиксированной ширины и окно Парзена переменной ширины. Также были выполнены подбор гиперпараметров по LOO-контролю, проверка влияния масштабирования признаков, построение карт классификации, анализ weighted-kNN при шуме, вычисление профиля компактности и жадный отбор эталонов.

Эксперименты показали, что качество метрических методов определяется не одним параметром, а сочетанием выбранной метрики, масштаба признаков, числа соседей, ширины окна и локальной структуры классов. Стандартизация признаков особенно важна для данных

с разными диапазонами значений. Увеличение k и h повышает устойчивость метода, но при чрезмерном сглаживании может ухудшать качество. Weighted-kNN оказался полезным не во всех случаях, поэтому его преимущество необходимо проверять экспериментально.

Таким образом, метрические классификаторы являются простыми и интерпретируемыми методами, но требуют аккуратного выбора гиперпараметров и предварительной обработки признаков. Наилучший результат достигается не за счёт одного универсального алгоритма, а за счёт подбора параметров под конкретную задачу и проверки качества на независимых данных.

Код и воспроизводимость

Код экспериментов представлен в Google Colab. Для воспроизводимости используется `fixed random_state = 42` там, где выполняется случайное разбиение данных; при сравнении kNN и weighted-kNN результаты усредняются по нескольким запускам. Время предсказания может отличаться при повторном запуске, поэтому оно используется как практическая иллюстрация ускорения, а не как абсолютная характеристика метода.

Ссылка на гитхаб:

<https://github.com/Julia2s/funcan/tree/main/case5>

Ссылка на гугл-колаб код:

<https://colab.research.google.com/drive/1y5JhA78EZ3KAX-ajbQw0HQ6pZRo1tDjh?usp=sharing>

Список использованных источников

1. Воронцов К. В. Лекции по метрическим алгоритмам классификации.

Режим доступа: <https://www.ccas.ru/voron/download/MetricAlgs.pdf>

Из источника использованы основные теоретические сведения о метрических алгоритмах классификации: гипотеза компактности, общий вид метрического классификатора, метод ближайшего соседа, метод k ближайших соседей, взвешенный kNN, окно Парзена, переменное окно Парзена, профиль компактности и полный скользящий контроль LOO.

2. Метрический классификатор и метод ближайших соседей.

Режим доступа:

<https://neerc.ifmo.ru/wiki/index.php?title=%D0%9C%D0%B5%D1%82%D1%80%D0%B8%D1%8>

7%D0%B5%D1%81%D0%BA%D0%B8%D0%B9_%D0%BA%D0%BB%D0%B0%D1%81%D1%81%D0%B8%D1%84%D0%B8%D0%BA%D0%B0%D1%82%D0%BE%D1%80_%D0%B8_%D0%BC%D0%B5%D1%82%D0%BE%D0%B4_%D0%B1%D0%BB%D0%B8%D0%B6%D0%B0%D0%B9%D1%88%D0%B8%D1%85_%D1%81%D0%BE%D1%81%D0%B5%D0%B4%D0%B5%D0%B9

Из источника использованы определения метрического классификатора, функции расстояния между объектами, правила классификации по ближайшим соседям и идеи голосования объектов обучающей выборки при определении класса нового объекта.

3. Метод парзеновского окна. MachineLearning.ru.

Режим доступа:

https://www.machinelearning.ru/wiki/index.php?title=Метод_парзеновского_окна

Из источника использованы сведения о методе окна Парзена: классификация на основе ядерной функции, зависимость веса объекта от расстояния, роль ширины окна h и отличие локального сглаживания от обычного голосования ближайших соседей.

4. Документация scikit-learn

<https://scikit-learn.ru/stable/modules/preprocessing.html>

https://scikit-learn.ru/stable/modules/cross_validation.html

https://scikit-learn.org/stable/datasets/toy_dataset.html

Из источника использованы сведения о стандартизации признаков с помощью StandardScaler, разделении выборки на обучающую и тестовую части, воспроизводимости экспериментов через random_state, а также описание встроенных наборов данных Iris, Wine и Breast Cancer, которые применялись в численных экспериментах.