

Министерство науки и высшего образования Российской
Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Кейс №6
"Метрические методы регрессии"
по дисциплине
"Функциональный анализ"

Семестр IV

Выполнили:

студент

Абаянцева Евгения Юрьевна

группа J3211

ИСУ: 327004

студент

Смольникова Юлия Юрьевна

группа J3211

ИСУ: 474363

студент

Лорс Алина Абуевна

группа J3214

ИСУ: 474321

Санкт-Петербург
2026

Содержание

1	Введение	3
2	Цель работы	4
3	Постановка задачи	4
4	Методы ядерного сглаживания и робастной регрессии	5
4.1	Функции ядер	5
4.2	Подходы к определению ширины окна сглаживания . . .	6
4.3	Робастный алгоритм LOWESS	7
5	Графики для одномерной синтетической задачи	8
6	Оценка метрик для реальных датасетов	10
6.1	Метрики для Diabetes Dataset	10
6.2	Метрики для California Housing	11
7	Сравнение обычной ядерной регрессии и робастной LOWESS	12
7.1	Общие выводы по выбору ядер	13
8	Графический анализ робастности моделей регрессии	13
9	Выводы и результаты	14
10	Список литературы	16
11	Ссылка на репозиторий	16

1 Введение

Пусть дана обучающая выборка:

$$X^\ell = \{(x_i, y_i)\}_{i=1}^\ell, \quad x_i \in \mathbb{R}^n, \quad y_i \in \mathbb{R}$$

Пусть для этой выборки выполняется гипотеза непрерывности (то есть близким объектам соответствуют близкие ответы). Тогда рассмотрим задачу непараметрической регрессии на основе ядерного сглаживания. Для объекта x оценим значение регрессии по формуле Надарая-Ватсона:

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^\ell y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^\ell K\left(\frac{\rho(x, x_i)}{h}\right)},$$

где $K(r)$ – ядро, $h > 0$ – ширина окна, $\rho(x, x_i)$ – расстояние между объектами.

Также будем исследовать вариант переменной ширины окна:

$$h(x) = \rho(x, x_{(k+1)})$$

А также будем исследовать оценку:

$$a(x; X^\ell, k) = \frac{\sum_{i=1}^\ell y_i K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}{\sum_{i=1}^\ell K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}$$

Значит, оценка Надарая-Ватсона может быть получена как решение задачи локально взвешенного метода наименьших квадратов при локальной модели:

$$f(x_i) \approx \theta$$

то есть:

$$Q(\theta; x) = \sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right) (\theta - y_i)^2 \rightarrow \min_{\theta}$$

Для борьбы с выбросами будем исследовать робастную схему под названием LOWESS. На итерации будут вычисляться LOO-оценки:

$$a_i = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}$$

После чего объектные веса будут обновляться по правилу:

$$\gamma_i = \tilde{K}\left(\frac{|a_i - y_i|}{6 \operatorname{med}\{\varepsilon_i\}}\right), \quad \varepsilon_i = |a_i - y_i|$$

2 Цель работы

Цель работы заключается в том, чтобы исследовать, как выбор ядра, ширины окна и робастного «перевзвешивания» влияет на качество регрессии и устойчивость к выбросам. Теперь перейдём к постановке задачи.

3 Постановка задачи

1. Нужно реализовать с нуля следующие регрессии:
 - ядерную регрессию Надарая-Ватсона с фиксированным окном;
 - ядерную регрессию Надарая-Ватсона с переменным окном;
 - робастную регрессию LOWESS.
2. Реализовать подбор h, k и ядра K по LOO или кросс-валидации;
3. Сравнить не менее трёх ядер (выбраны гауссовское, Япанечникова и треугольное ядра);
4. Построить графики для одномерной синтетической задачи;

5. Оценить качество по метрикам (MAE, RMSE и R^2);
6. Добавить в данные искусственные выбросы и сравнить обычную ядерную регрессию и LOWESS;
7. Построить графики для весов, сравнения и распределения ошибок;
8. Сделать по всей работе выводы (ответить на следующие вопросы):
 - Что влияет на качество сильнее – выбор ядра или выбор ширины окна;
 - Когда переменное окно выигрывает у фиксированного;
 - При каком уровне загрязнения данных LOWESS начинает выигрывать у обычного сглаживания.

Выбраны два датасета (diabetes-data-set и california-housing-prices), а также одномерная синтетическая задача ($y = \sin x + \varepsilon$).

4 Методы ядерного сглаживания и робастной регрессии

4.1 Функции ядер

Ядерные функции $K(r)$ определяют характер распределения весов объектов выборки в зависимости от расстояния до оцениваемой точки. В данной работе реализованы и исследованы три типа гладких симметричных ядер с ограниченным носителем (кроме гауссовского):

1. **Гауссовское ядро (Gaussian kernel):** это ядро обладает бесконечным носителем, обеспечивая максимальную гладкость регрессионной кривой:

$$K(r) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}r^2\right)$$

Гауссовское ядро обладает бесконечным носителем ($r \in (-\infty, +\infty)$), что означает, что в расчёт прогноза в той или иной степени будут вноситься абсолютно все объекты обучающей выборки, даже

самые удаленные. За счёт бесконечной дифференцируемости экспоненты гауссовское ядро обеспечивает максимальную, идеально гладкую аппроксимацию регрессионной кривой без изломов. Оно крайне эффективно при моделировании физических и непрерывных процессов, где отсутствуют резкие скачки и разрывы целевой зависимости.

2. **Ядро Епанечникова (Epanechnikov kernel):** это ядро оптимально с точки зрения минимизации среднеквадратичной ошибки:

$$K(r) = \frac{3}{4}(1 - r^2) \cdot [|r| \leq 1]$$

Ядро Епанечникова относится к классу ядер с ограниченным носителем (функция определена только на отрезке $[-1, 1]$), то есть алгоритм полностью обнуляет веса объектов, вышедших за пределы окна сглаживания. Математически доказано, что ядро Епанечникова является оптимальным с точки зрения минимизации асимптотической среднеквадратичной ошибки. Веса убывают к краям окна по квадратичной параболе, обеспечивая гладкое непрерывное сопряжение на границе окна ($K(1) = 0$), что минимизирует вычислительный шум при входе/выходе точек из зоны сглаживания.

3. **Треугольное ядро (Triangular kernel):** это ядро линейно убывает по мере удаления от центра окна сглаживания:

$$K(r) = (1 - |r|) \cdot [|r| \leq 1]$$

Треугольное ядро также имеет строго ограниченную зону действия на отрезке $[-1, 1]$. Веса убывают линейно по мере удаления от центра. В отличие от ядра Епанечникова, треугольное ядро не обладает идеальной гладкостью на границах и в самом центре ($r = 0$), так как его первая производная имеет изломы. Однако за счет линейности оно вычислительно более простое и эффективно применяется там, где нужно уловить кусочно-линейные тренды в данных.

4.2 Подходы к определению ширины окна сглаживания

Качество аппроксимации в непараметрической регрессии критически зависит от параметра сглаживания (ширины окна). В работе было взято

два подхода, одно через фиксированной ширины окна, другой через переменную:

- **Фиксированная ширина окна ($h = \text{const}$):** радиус сглаживания одинаков во всех точках пространства признаков. Метод эффективен при относительно равномерной плотности распределения объектов. При наличии сильной разреженности данных фиксированное окно может приводить к эффекту «пустых окон» и неустойчивости оценки.
- **Переменная ширина окна ($h(x) = \rho(x, x_{(k+1)})$):** ширина окна динамически подстраивается под локальную плотность выборки и определяется расстоянием до $(k + 1)$ -го ближайшего соседа. В областях высокой плотности окно сужается, сохраняя высокую локальную точность, а в разреженных областях – расширяется, предотвращая вычислительные сбои.

4.3 Робастный алгоритм LOWESS

Для обеспечения помехоустойчивости (робастности) непараметрической регрессии применяется алгоритм локально взвешенного сглаживания диаграмм рассеяния (LOWESS). Процедура позволяет выявлять и исключать из расчёта аномальные наблюдения (выбросы) путём итеративного перевзвешивания.

Разберём пошаговый алгоритм реализации LOWESS. Он выглядит следующим образом:

1. Инициализируем для всех объектов выборки начальные веса устойчивости $\gamma_i = 1, \quad i = 1, \dots, \ell$;
2. После этого на каждой итерации $t = 1, \dots, T$:
 - а) Для каждого объекта x_i вычисляем оценку скользящего контроля (Leave-One-Out) по формуле Надарая-Ватсона с учётом текущих весов устойчивости γ_j :

$$a_i = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}$$

- б) Находим вектор абсолютных ошибок (остатков) модели на обучающих объектах:

$$\varepsilon_i = |a_i - y_i|, \quad i = 1, \dots, \ell$$

- в) Вычисляем медиану полученных остатков: $\text{med}\{\varepsilon_i\}$;
 г) После чего корректируем веса устойчивости γ_i с использованием робастного квадратичного ядра (ядра Бивеса):

$$\gamma_i = \tilde{K} \left(\frac{\varepsilon_i}{6 \cdot \text{med}\{\varepsilon_i\}} \right), \quad \text{где } \tilde{K}(r) = (1 - r^2)^2 \cdot [|r| \leq 1]$$

Если ошибка ε_i объекта будет превышать порог $6 \cdot \text{med}\{\varepsilon_i\}$, то его робастный вес γ_i становится равным нулю, что полностью исключает аномальный объект из дальнейшего процесса сглаживания.

5 Графики для одномерной синтетической задачи

Для синтетической одномерной задачи ($y = \sin x + \varepsilon$) были построены графики:

- а) График истинной функции, наблюдений и прогноза при различных значениях h :




Рис. 1: Ядерная регрессия Надарая-Ватсона при различных значениях окна сглаживания h

- б) График зависимости среднеквадратичной ошибки от ширины фиксированного окна h :




Рис. 2: Зависимость среднеквадратичной ошибки от фиксированного окна

- в) График зависимости среднеквадратичной ошибки от числа соседей k :




Рис. 3: Зависимость среднеквадратичной ошибки от числа соседей

6 Оценка метрик для реальных датасетов

Для оценки качества разработанных алгоритмов в условиях многомерных пространств признаков были использованы два реальных набора данных: Diabetes Dataset (задача медицинской диагностики) и California Housing (задача экономического прогнозирования стоимости недвижимости). Здесь мы использовали пункт 3 в виде подбора оптимального типа ядра и пункт 2 в виде подбора параметров сглаживания, который воспроизводится автоматически на основе минимизации ошибки скользящего контроля (LOO).

6.1 Метрики для Diabetes Dataset

Данный датасет характеризуется высокой зашумленностью и сложной, нелинейной структурой связей между медицинскими показателями пациентов. Результаты тестирования представлены в следующей таблице:

Метод окна	Лучшее ядро	MAE	RMSE	R^2
Фиксированное ($h = 1.48$)	Гауссовское	0.329	0.382	0.373
Переменное ($k = 30$)	Епанечникова	0.324	0.390	0.345

Таблица 1: Метрики качества аппроксимации для Diabetes Dataset

По полученным результатам можно сделать следующие выводы:

- Коэффициент детерминации $R^2 \approx 0.35 - 0.37$ указывает на то, что модель успешно улавливает около 36% дисперсии целевой переменной. Для зашумленных медицинских данных, где признаки имеют разную физическую природу, а целевой признак бинарен, данный результат является хорошим показателем для базовых ядерных методов;
- Фиксированное окно с гауссовским ядром показало наилучший результат по метрике R^2 (0.373). Это говорит о том, что после предварительного масштабирования признаков (StandardScaler) плотность распределения объектов в пространстве оказалась относительно равномерной. В таких условиях жестко заданный радиус сглаживания $h = 1.48$ обеспечивает стабильное усреднение ответов соседей.

6.2 Метрики для California Housing

В данной задаче прогнозируется непрерывная величина – стоимость жилья в долларах США. Результаты представлены в следующей таблице:

Метод окна	Лучшее ядро	MAE	RMSE	R^2
Фиксированное ($h = 0.46$)	Гауссовское	30 389.898	49 259.695	0.673
Переменное ($k = 22$)	Треугольное	35 790.232	54 834.691	0.595

Таблица 2: Метрики качества аппроксимации для California Housing

По полученным результатам можно сделать следующие выводы:

- Значение $R^2 = 0.673$ для фиксированного окна является **высоким показателем эффективности**. Разработанный непараметрический алгоритм смог объяснить 67.3% изменчивости цен на недвижимость, что сопоставимо со сложными параметрическими моделями;
- Оптимальное фиксированное окно получилось достаточно узким ($h = 0.46$). Это легко объясняется экономической спецификой данных: стоимость недвижимости в Калифорнии жестко привязана к географическим координатам (локации). Цены могут резко меняться от квартала к кварталу, поэтому для точного прогноза модели необходимо учитывать только очень близких географических и экономических «соседей», не размывая оценку по далеким объектам. На бесконечном носителе гауссовского ядра это сработало идеально;
- Фиксированное окно существенно обошло переменное окно по качеству (R^2 : 0.673 против 0.595). При переменном окне ($k = 22$) в областях с высокой плотностью застройки радиус окна сильно сжимался, что приводило к недосглаживанию и росту чувствительности к локальному шуму. В то же время треугольное ядро на краях окна имеет изломы производной, что добавило неустойчивости предсказаниям по сравнению с бесконечно гладким гауссовским ядром.

Общие выводы по выбору ядер представлены в блоке «Выводы и результаты».

7 Сравнение обычной ядерной регрессии и робастной LOWESS

При подготовке к сравнению регрессий сначала была сделана одномомерная выборка из $\ell = 100$ точек на основе функции $y = \sin(x)$ с добавлением случайного некоррелированного шума. Мы внесли в данные искусственно 5 крупных изолированных выбросов (в точках с индексами 5, 15, 50, 70 и 85), которые имитируют грубые ошибки измерений. На этих «загрязненных» данных было проведено сравнение классической ядерной регрессии Надарая-Ватсона и робастного алгоритма LOWESS с фиксированным числом шагов перевзвешивания ($T = 3$). Качество восстановления скрытой истинной зависимости $\sin(x)$ оценивалось относительно чистой, не зашумленной функции.

Результаты численного сравнения моделей на выборке с аномалиями представлены в следующей таблице:

Алгоритм регрессии	MAE	RMSE	R^2
Обычный Надарая-Ватсон	0.230	0.315	0.813
Робастный LOWESS	0.085	0.102	0.980

Таблица 3: Метрики качества восстановления истинной зависимости в условиях выбросов

По полученным результатам можно сделать следующие выводы:

- Сначала рассмотрим коэффициент детерминации R^2 . Алгоритм LOWESS показывает практически идеальное качество восстановления исходной синусоиды ($R^2 = 0.980$), полностью игнорируя внесенный хаос. В то же время у классического метода Надарая-Ватсона показатель детерминации существенно просел ($R^2 = 0.813$), что указывает на сильное смещение аппроксимирующей кривой;
- Теперь рассмотрим ошибки MAE и RMSE. Для LOWESS значения MAE (0.085) и RMSE (0.102) практически совпадают. Отсутствие сильного разрыва между средней и среднеквадратичной ошибкой – это показатель того, что в остатках робастной модели полностью отсутствуют крупные промахи. У Надарая-Ватсона RMSE (0.315) значительно превышает MAE (0.230), поскольку квадратичный штраф в метрике RMSE резко реагирует на сильные локальные искажения кривой в окрестностях аномалий.

7.1 Общие выводы по выбору ядер

Эксперименты выявили важную закономерность: во всех тестах с фиксированным окном лучшим было выбрано Гауссовское ядро, а для переменного окна – ядра с ограниченным носителем (Епанечникова и Треугольное). Это можно объяснить фундаментальными свойствами алгоритмов:

1. Бесконечный носитель гауссовской функции экспоненциально снижает веса далеких точек, но никогда не обнуляет их полностью, что страхует фиксированное окно от вычислительных сбоев (деления на ноль) в разреженных зонах пространства;
2. Ядра с ограниченным носителем идеально подходят для схемы k ближайших соседей, так как они естественным образом зануляют веса всех объектов, не вошедших в заданное число соседей k , обеспечивая строго локальное и вычислительно эффективное сглаживание.

8 Графический анализ робастности моделей регрессии

Также для этой синтетической одномерной задачи были построены графики сравнения, весов и распределения:

а) График весов γ_i после стабилизации LOWESS:




Рис. 4: Финальные робастные веса в алгоритме LOWESS

- б) График сравнения кривых прогноза до и после робастного перевзвешивания:




Рис. 5: Краш тест

- в) График распределения ошибок на объектах:




Рис. 6: Гистограмма распределения ошибок

9 Выводы и результаты

В ходе выполнения лабораторной работы были реализованы, протестированы и проанализированы алгоритмы непараметрической ядерной

регрессии Надарая-Ватсона и робастного сглаживания LOWESS. На основе проведенных вычислительных экспериментов как на синтетических данных, так и на реальных датасетах, мы можем сформулировать следующие ключевые выводы по вопросам из пункта 8:

1. Что влияет на качество сильнее — выбор ядра или выбор ширины окна?

Эксперименты однозначно показали, что выбор ширины окна сглаживания (h или k) оказывает критически более сильное влияние на качество аппроксимации, нежели выбор функции ядра. Недорасчет или перерасчет ширины окна приводит к двум классическим проблемам машинного обучения:

- а) Слишком маленькое окно сглаживания вызывает недосглаживание (то есть переобучение), при котором модель начинает интерполировать случайный шум;
- б) Слишком же большое окно приводит к пересглаживанию (то есть недообучению), стирая важные локальные особенности и тренды целевой зависимости.

В то же время, изменение типа ядра при фиксированном оптимальном окне лишь незначительно корректирует гладкость регрессионной функции и косметически варьирует метрики качества (R^2 , MAE) в пределах сотых долей;

2. Когда переменное окно выигрывает у фиксированного?

Переменное окно (метод k ближайших соседей) демонстрирует математическое преимущество над фиксированным в условиях существенно неравномерной плотности распределения объектов в пространстве признаков.

В разреженных областях (на краях распределения или в местах нехватки данных) фиксированное окно h рискует оказаться «пустым», что делает оценку Надарая-Ватсона неопределенной или крайне неустойчивой. Переменное окно в таких зонах адаптивно расширяется, гарантируя сбор информации по k соседям. Однако на сбалансированных и предварительно отмасштабированных данных (как в случае с использованными датасетами после StandardScaler) фиксированное окно с бесконечно гладким гауссовским ядром способно улавливать тонкие локальные закономерности точнее, что подтверждается его лидерством по метрике R^2 в обеих практических задачах (0.373 для Diabetes и 0.673 для California Housing);

3. При каком уровне загрязнения данных LOWESS начинает выигрывать у обычного сглаживания?

Алгоритм LOWESS начинает превосходить классический метод Надарая-Ватсона при любом уровне загрязнения, содержащем единичные или множественные крупные изолированные аномалии (выбросы), чья амплитуда существенно превышает стандартное отклонение основного шума данных.

Обычное ядерное сглаживание минимизирует локальную средне-квадратичную ошибку, из-за чего кривая регрессии неустойчива и квадратично смещается в сторону аномальной точки, искажая прогнозы для нормального «соседства».

Как показал краш-тест на синусоиде с введением 5% грубых выбросов, LOWESS за счет итеративного перевзвешивания с использованием ядра Бивеса полностью зануляет веса аномальных объектов ($\gamma_i = 0$). Это позволяет робастной модели сохранять идеальное качество аппроксимации ($R^2 = 0.980$ против 0.813 у Надарая-Ватсона) и локальную стабильность, изолируя ошибку на самих поврежденных точках.

10 Список литературы

Использованная литература:

1. Ядерная оценка плотности, статья с википедии;
2. Ядерная оценка неизвестной плотности вероятности;
3. Статья на тему «Применение ядерной оценки плотности вероятности для решения задачи классификации технического состояния сложных систем»;

11 Ссылка на репозиторий

Ссылка на репозиторий с кодом